Yifei Liu (刘亦飞)

nephrencake@sjtu.edu.cn | Homepage | Google Scholar | GitHub

教育经历

上海交通大学 | 工科硕士 | 计算机系，计算机学院 *@EPCC* 2023.09—2026.03

导师：陈晨教授

南京工业大学 | 工科学士 | 计算机系，计算机学院 2019.09—2023.06

工作经历

小红书 | 大模型推理研发工程师 *@RAI Studio* 2026.03—至今

- 主导混合注意力模型的位置无关缓存，产出 HYPIC，ATC'26 已接收。
- 主导分布式位置无关缓存系统，产出 Nebula，NSDI'27 在投。
- 参与小红书问一问业务成本优化。

华为云 | 大模型推理优化实习生 *@XDS Team* 2024.09—2025.12

研究指导：单一舟

- 主导 Agent 调度优化，产出 Hermes，TACO'26 已发表。
- 主导高吞吐推理优化，产出 SC-Serve，EuroSys'27 在投。
- 参与 MoE 负载均衡、Attn-MoE 分离。

科研经历

已发表或录用 CCF-A 论文 5 篇（一作 3 篇），另有在投论文 12 篇（一作/共一 5 篇）。研究聚焦于大模型推理优化，主要包括位置无关缓存、GPU 空分复用、Agent 任务调度、缓存卸载/预取、MoE 加速算法/负载均衡等；此外也涉及训练集群任务调度和分布式缓存系统。

[1] HYPIC: Position-Independent Caching for Hybrid-Attention LLM Serving **ATC'26 [CCF-A]**

Yifei Liu, Juntong Wu, Yang Liu, Junhao Hu, Minghao Li, Xiaoxu Chen, Weihang Chen.

贡献：主导想法、实现与写作。业界第一个面向混合注意力模型的位置无关缓存。TTFT 加速 3.25×，QPS 提升 1.66×。

[2] Nebula: Distributed Position-Independent Caching for LLM Serving **NSDI'27 在投**

Yifei Liu, Junbin Pan, Junhao Hu, Yang Liu, Junyi Chen, Juntong Wu, Chen Chen, Haiyuan Zhao, Xiaoxu Chen, Weihang Chen.

贡献：主导想法、实现与写作。业界第一个分布式位置无关缓存系统。TTFT 降低 61.9% ，回收 76.4% 前缀缓存未命中。

[3] RedKnot: Efficient Long-Context LLM Serving with Head-Aware KV Reuse and SegPagedAttention **OSDI'27 在投**

Yang Liu, Zhaokai Luo, Huayi Jin, Zhiyong Wang, Ruozhou He, Boyu Wang, Guanjie Chen, **Yifei Liu**, Tao Xie, Junhao Hu.

贡献：提供想法与写作。业界第一个利用分头注意力的位置无关缓存。TTFT 加速 1.4–5.2×，并发容量提升 4.7–7.8×。

[4] SC-Serve: Semi-coupled Serving of Hybrid Online-Offline LLM Requests **EuroSys'27 在投**

Na Lyu, Yichen Bao, **Yifei Liu**, Yanbo Wang, Han Zhao, Weihao Cui, Mingliang Gong, Rui Fang, Zhonghui Jiang, Yongjie Yuan, Chen Chen.

贡献：主导想法、实验与写作。业界第一个利用 GPU 空分复用加速在离线混部服务。相同在线 SLO 满足率下，离线吞吐提高 1.58–1.83×。

[5] ExFold: Unified Expert Folding for Training-Free MoE Prefill-Decode Acceleration **AAAI'27 在投**

Juntong Wu, **Yifei Liu**, Junyi Chen, Siqi Fan, Chaoran Feng, Minghao Li, Liujie Zhang, Weihang Chen, Li Yuan.

贡献：提供想法与写作。通过专家折叠加速 MoE，近无损下提供 18% TTFT 和 29% TPOT 加速，已上线小红书问一问服务。

[6] Hermes: Efficient Serving of LLM Applications with Probabilistic Demand Modeling **TACO'26 [CCF-A]**

Yifei Liu, Zuo Gan, Zhenghao Gan, Weiye Wang, Chen Chen, Yizhou Shan, Xusheng Chen, Zhenhua Han, Yifei Zhu, Shixuan Sun, Minyi Guo.

贡献：主导想法、实验与写作。以概率需求图驱动调度与预热，平均应用完成时间降低超 70%。

[7] Ares: Fair and Efficient Scheduling of Deep Learning Jobs with Elastic Fair Queuing **TACO'25 [CCF-A]**

Yifei Liu, Chen Chen, Qiang Wang, Yu Feng, Weihao Cui, Quan Chen, Minyi Guo.

贡献：主导想法、实验与写作。按虚拟完成时间弹性分配 GPU，平均作业完成时间降低超 20%，不公平作业数减少超 40%。

[8] SageSched: Efficient LLM Scheduling Confronting Demand Uncertainty and Hybridity **NeurIPS'26 [CCF-A]**

Zhenghao Gan, Yichen Bao, **Yifei Liu**, Chen Chen, Quan Chen, Minyi Guo.

贡献：提供想法与写作。以输出长度分布和计算/显存成本驱动调度，平均 TTLT 降低超 28.7%。

[9] Justitia: Fair and Efficient Scheduling of Task-parallel LLM Agents with Selective Pampering **NeurIPS'26 [CCF-A]**

Mingyan Yang, Guanjie Wang, Manqi Luo, **Yifei Liu**, Chen Chen, Han Zhao, Yu Feng, Quan Chen, Minyi Guo.

贡献：提供想法与写作。以显存成本驱动虚拟时间公平调度，Agent 平均完成时间较 VTC 降低 57.5%。

[10] S-HPLB: Efficient LLM Attention Serving via Sparsity-Aware Head Parallelism Load Balance **AAAI'27 在投**

Di Liu, **Yifei Liu**, Chen Chen, Zhibin Yu, Xiaoyi Fan, Quan Chen, Minyi Guo.

贡献：提供想法与写作。联合优化注意力头稀疏度与负载均衡，注意力计算平均加速 2.88×。

[11] HydraCache: Semi-isolated Cache Management for Enterprise AI Clusters **EuroSys'27 在投**

Tianze Wang, **Yifei Liu**, Chen Chen, Pengfei Zuo, Jiawei Zhang, Qizhen Weng, Yin Chen, Zhenhua Han, Jieru Zhao, Quan Chen, Minyi Guo.

贡献：提供想法与写作。根据访问模式与粒度自适应管理缓存，作业完成时间降低 52.2%。

[12] Rethinking MoE Routing: Unlocking the Sparsity Potential of Pretrained Models **ICLR'27 在投**

Juntong Wu, Jialiang Cheng, **Yifei Liu**, Qishen Yin, Junyi Chen, Siqi Fan, Minghao Li, ZhangLiujie, Weihang Chen, Li Yuan.

[13] ToolSlack: Exploiting Tool Execution Windows for Efficient LLM Agent Serving **EuroSys'27 在投**

Yang Liu, **Yifei Liu**, Junhao Hu, Bing Tian, HuaYi Jin, Canhui Chen, Zhiyong Wang, NianQi Li, MingXiao Ma, Biao Zhang, RuoZhou He, ZhaoKai Luo.

[14] Akashic: A Low-Overhead LLM Inference Service with MemAttention **OSDI'27 在投**

Yang Liu, Zhaokai Luo, Huayi Jin, Ruozhou He, Chenchen Hong, Zhiyong Wang, **Yifei Liu**, Yunfei Gu, Chentao Wu, Junhao Hu.

[15] When Is Reuse Worth Replacing Exploration? Quality-Constrained Rollout Allocation for Stateful Agentic Reinforcement Learning **ICLR'27 在投**

Junyi Chen, Chenzhi Hu, Yuhang Xu, Juntong Wu, **Yifei Liu**, Yuanfan Li, Rui Yang, ZhangLiujie, Weihang Chen, Shengzhong Liu, Fan Wu, Guihai Chen.

[16] GDPevo: Evaluating Agent Self-Evolution on Real Business Tasks **ICLR'27 在投**

Leijun Zhou, Zhihao Liu, Xiang Qu, Chenxu Liu, **Yifei Liu**, Yanke Yu, Jingzhe Xu, Xuejun Wu, Buyue Qian, Xi Chen, Yaowei Zheng, Junhao Hu.

[17] Automatic Training Configuration with Gradient Signal for Resource-Efficient Training-as-a-service **TCC'27 在投**

Guanjie Wang, Chen Chen, **Yifei Liu**, Qiang Wang, Cong Wang, Quan Chen, Minyi Guo.

专业技能

- **语言**: 不受特定语言限制。熟练使用 Python、Pytorch。了解 CUDA、Triton、C++、Rust、Golang、Java。
- **框架**: 掌握 vLLM、SGLang 框架，并能在其上进行二次开发。
- **工具**: Linux、Git、Docker、Vim、Shell。
- **AI 工具**: 熟练使用 codex、cc，重度 vibe coding 患者。